딥러닝을 이용한 자연어 처리

인공지능 비서가 갖춰야 할 필수 능력은 사람의 언어를 이해하는 것
-> **자연어 처리(Natural Language Processing, NLP)**

자연어 - 우리가 평소에 말하는 음성이나 텍스트
자연어 처리 - 음성이나 텍스트를 컴퓨터가 인식하고 처리하는 것

딥러닝이 등장하면서 자연어 처리 연구가 활발해지기 시작했습니다. 이는 대용량 데이터를 학습할 수 있는 딥러닝의 속성 때문이다.

컴퓨터 알고리즘은 수치로 된 데이터만 이해할 뿐 텍스트를 이해할 수 없기 때문에 텍스트를 정제하는 **전처리 과정**이 꼭 필요함!

1. 텍스트의 토큰화

(실습코드는 github 참고)
토큰(token) - 텍스트를 단어별, 문장별, 형태소별로 나누었을 때, 작게 나누어진 하나의 단위
토큰화(tokenization) - 텍스트를 잘게 나누는 과정

케라스가 제공하는 text 모듈의 text_to_word_sequence() 함수를 사용하면 문장을 단어 단위로 쉽게 나눌 수 있음

Bag-of-Words 방법- 같은 단어끼리 따로따로 가방에 담은 뒤 각 가방에 몇 개의 단어가 들어있는지를 세는 기법

케라스의 Tokenizer() 함수를 사용하면 단어의 빈도 수를 쉽게 계산할 수 있음
(word_counts는 단어의 빈도 수를 계산해주는 함수)
(순서를 기억하는 OrderedDict 클래스에 담겨 있는 형태로 출력됨)

document_count() 함수 - 몇 개의 문장이 들어있는지 셀 수 있음

word_docs() 함수 - 각 단어들이 몇 개의 문장에 나오는가를 세어서 출력할 수 있음(출력되는 순서는 랜덤)

word_index() 함수 - 각 단어에 매겨진 인덱스 값을 출력
(각 단어의 빈도수가 높은 순서대로 인덱스가 부여됨)

2. 단어의 원-핫 인코딩

단어의 출현 빈도만 가지고는 해당 단어가 문장의 어디에서 왔는지, 각 단어의 순서는 어떠했는지 등에 관한 정보를 얻을 수 없음

단어가 문장의 다른 요소와 어떤 관계를 가지고 있는지 알아보는 방법이 필요함
-> **원-핫 인코딩** 사용!

각 단어를 모두 0으로 바꾸어 주고 원하는 단어만 1로 바꾸어 주는 것이 원-핫 인코딩
(파이썬 배열의 인덱스는 0부터 시작하므로, 맨 앞에 0이 추가되는 것에 주의)

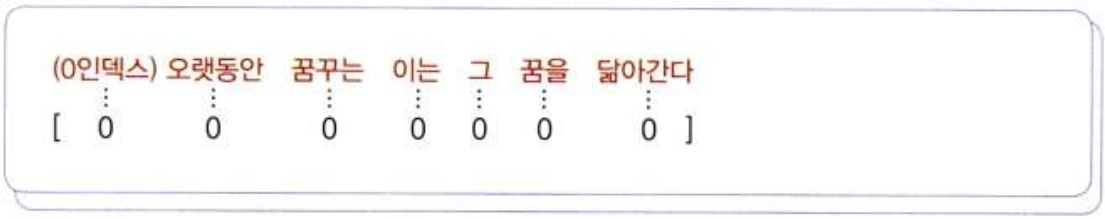

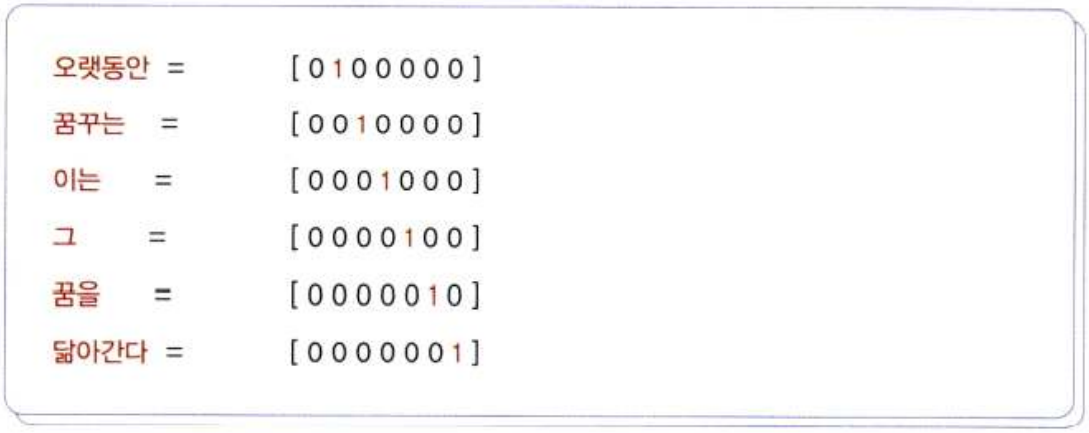

texts_to_sequences() 함수 - 토큰의 인덱스로만 채워진 새로운 배열 만들기

to_categorical() 함수 - 0과 1로만 이루어진 배열로 바꾸어주는 원-핫 인코딩 진행

3. 단어 임베딩

원-핫 인코딩을 그대로 사용하면 벡터의 길이가 너무 길어진다는 단점이 있음 -> 공간적 낭비를 해결하기 위해 등장한 것이 바로 **단어 임베딩(word embedding)**

단어 임베딩으로 얻은 결과가 밀집된 정보를 가지고 있고 공간의 낭비가 적다.
-> 이런 결과가 가능한 이유는 각 단어 간의 유사도를 계산했기 때문

유사도 계산에는 오차 역전파 사용
적절한 크기로 배열을 바꾸어 주기 위해 최적의 유사도를 계산하는 학습 과정을 거친다.
(Embedding() 함수 사용)

Embedding() 함수에는 '입력'과 '출력'의 크기를 나타내는 매개변수 2개가 필요하며 input_length를 따로 지정해 단어를 매번 얼마나 입력할지를 추가로 지정할 수 있다.

4. 텍스트를 읽고 긍정, 부정 예측하기

(실습코드는 github 참고)

딥러닝 모델에 입력을 하려면 학습 데이터의 길이가 동일해야 함

패딩(padding) - 길이를 똑같이 맞춰 주는 작업

pad_sequence() 함수 - 원하는 길이보다 짧은 부분은 숫자 0을 넣어서 채워주고, 긴 데이터는 잘라서 같은 길이로 맞춤

최적화 함수로 adam()을 사용하고 오차 함수로는 binary_crossentropy()를 사용함. 30번 반복하고나서 정확도를 계산해 출력하게 함.

참고자료

https://taeguu.tistory.com/69